TRƯỜNG ĐẠI HỌC KINH TẾ QUỐC DÂN

KHOA TOÁN KINH TẾ

***

ĐỀ ÁN:

ỨNG DỤNG MÔ HÌNH PHÂN LOẠI DỰ BÁO RỦI RO TÍN DỤNG KHÁCH HÀNG CÁ NHÂN TẠI NOVA BANK

Họ tên: Trần Anh Quân

Mã sinh viên: 11233244

Lớp: Toán Kinh tế 65

Gv hướng dẫn: Th.S Đào Bùi Kiên Trung

Hà Nội, Tháng 7-2026

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn đến thầy Đào Bùi Kiên Trung, người đã hướng dẫn và đồng hành cùng em trong quá trình thực hiện đề án này, đồng thời cũng là giảng viên cố vấn học tập của lớp Toán Kinh tế 65. Những kiến thức quý báu, sự chỉ dẫn nhiệt tình và những lời khuyên quý giá của thầy đã giúp em rất nhiều trong việc tìm kiếm và phát triển ý tưởng cho đề tài nghiên cứu.

Em cũng xin gửi lời cảm ơn đến các giảng viên Trường Đại học Kinh tế Quốc dân, đặc biệt là các thầy cô giảng viên Khoa Toán Kinh tế đã tạo điều kiện thuận lợi trong suốt quá trình học tập và nghiên cứu.

Dù đã cố gắng trong quá trình thực hiện đề án nhưng đề án này của em vẫn còn rất nhiều thiếu sót. Em rất mong nhận được sự góp ý của các thầy cô để em có thể sửa sai và hoàn thiện hơn trong khoá luận tốt nghiệp.

Em xin chân thành cảm ơn!

Người thực hiện

Trần Anh Quân

MỤC LỤC

LỜI CẢM ƠN **2**

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI **5**

1.1: Lí do chọn đề tài 5

1.2: Mục tiêu nghiên cứu 5

1.3: Đối tượng và phạm vi nghiên cứu 6

1.3.1. Đối tượng nghiên cứu 6

1.3.2. Phạm vi nghiên cứu 6

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT **7**

2.1: Rủi ro tín dụng 7

2.2: Bài toán phân loại 7

2.3: Tiêu chí đánh giá mô hình 7

2.4: Các mô hình nghiên cứu 8

2.4.1: Logistic Regression 8

2.4.2: Random Forest 8

2.4.3: XGBoost 9

CHƯƠNG 3: DỮ LIỆU VÀ TIỀN XỬ LÍ DỮ LIỆU **9**

3.1: Mô tả dữ liệu 9

3.2: Tiền xử lý 11

3.2.1: Kiểm tra giá trị thiếu 11

3.2.2: Xử lí outliers 11

3.2.3: Mã hoá biến phân loại 12

3.2.4: Chuẩn hoá dữ liệu 13

3.3: Kiểm định đa cộng tuyến và phân chia dữ liệu 13

CHƯƠNG 4: PHÂN TÍCH KẾT QUẢ MÔ HÌNH HỌC MÁY **15**

4.1: So sánh hiệu suất các mô hình cơ sở 15

4.2: Tối ưu hoá siêu tham số cho mô hình XGBoost 15

4.3: Xác định ngưỡng quyết định theo chi phí kinh doanh 15

4.4: Đánh giá kết quả trên tập kiểm thử độc lập 16

4.5: Giải thích mô hình bằng SHAP 18

CHƯƠNG 5: HẠN CHẾ CỦA ĐỀ TÀI VÀ HƯỚNG PHÁT TRIỂN **20**

5.1: Hạn chế 20

5.2: Hướng phát triển 20
KẾT LUẬN **21**
TÀI LIỆU THAM KHẢO **22**

Danh mục hình ảnh

Hình 3.1. Phân phối biến mục tiêu loan_status (Không vỡ nợ vs Vỡ nợ) 9
Hình 3.2. Boxplot so sánh trước/sau Winsorizing của person_income, loan_int_rate, person_age 12
Hình 3.3. Ma trận tương quan giữa các biến số 14
Hình 4.1. Trade-off giữa ngưỡng quyết định (threshold) và tổng chi phí kinh doanh ước tính 16
Hình 4.2. Đường cong ROC của mô hình XGBoost trên tập Train và tập Test 17
Hình 4.3. Đường cong Precision–Recall với điểm ngưỡng tối ưu 0.404 18
Hình 4.4. Ma trận nhầm lẫn trên Test tại ngưỡng quyết định 0.404 18
Hình 4.5. Biểu đồ SHAP Summary Plot – Các yếu tố cốt lõi chi phối rủi ro vỡ nợ 19

Danh mục bảng

Bảng 1. Mô tả các biến trong bộ dữ liệu tín dụng cá nhân Nova Bank 10
Bảng 2: Hệ số phóng đại phương sai (VIF) của các biến số trước khi huấn luyện mô hình 13
Bảng 3: Kích thước các tập dữ liệu Train / Validation / Test 14
Bảng 4: Kết quả so sánh hiệu suất các mô hình cơ sở bằng 5-Fold Cross Validation 15
Bảng 5: Bộ siêu tham số tối ưu của mô hình XGBoost sau RandomizedSearchCV 15
Bảng 6: Ngưỡng quyết định theo hai chiến lược hiệu chỉnh 16
Bảng 7: So sánh AUC giữa tập Train và tập Test 16
Bảng 8: Báo cáo phân loại chi tiết trên tập Test (ngưỡng quyết định = 0.404) 17

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1: Lí do chọn đề tài

Trong bối cảnh hệ thống tài chính ngày càng biến động và cạnh tranh khốc liệt, hoạt động cấp tín dụng bán lẻ luôn đóng vai trò là nghiệp vụ cốt lõi, mang lại nguồn thu nhập chủ yếu cho các ngân hàng thương mại. Tuy nhiên, đi liền với mục tiêu tăng trưởng lợi nhuận là áp lực khổng lồ từ rủi ro tín dụng. Việc xác định sai khả năng hoàn trả của người vay không chỉ trực tiếp làm gia tăng tỷ lệ nợ xấu, bào mòn lợi nhuận mà còn đe dọa đến tỷ lệ an toàn vốn và giảm khả năng thanh khoản của ngân hàng.

Với quy trình cũ, việc thẩm định và ra quyết định cấp tín dụng thường phụ thuộc nhiều vào kinh nghiệm của các chuyên viên. Phương pháp này bộc lộ rõ nhiều điểm nghẽn: mang tính chủ quan cao, thời gian xử lý kéo dài, khó mở rộng quy mô giải ngân, và đặc biệt là bỏ lỡ khối lượng dữ liệu giao dịch khổng lồ đang ngày một phình to trong hệ thống lõi (Core Banking).

Trên thực tế hiện nay, việc ứng dụng các mô hình định lượng và thuật toán học máy (Machine Learning) để chấm điểm tín dụng không còn là một khái niệm mới mẻ. Các tổ chức tài chính đang bước vào một cuộc đua số hóa toàn diện, chuyển dịch từ thẩm định thủ công sang xây dựng các hệ thống phê duyệt tự động nhằm tối ưu hóa quy trình quản trị rủi ro.

Nắm bắt xu hướng chuyển đổi tất yếu đó, cùng với bài toán cốt lõi của Nova Bank trong việc tìm kiếm điểm cân bằng giữa mở rộng khả năng tiếp cận tín dụng và bảo vệ ngân hàng trước rủi ro vỡ nợ, tôi đã lựa chọn đề tài **"Ứng dụng mô hình phân loại dự báo rủi ro tín dụng khách hàng cá nhân tại Nova Bank"** . Việc nghiên cứu và xây dựng mô hình dự báo này không chỉ cung cấp một công cụ đánh giá khách quan, minh bạch mà còn là bước đi hoàn toàn phù hợp với dòng chảy công nghệ của ngành ngân hàng hiện đại, tạo cơ sở vững chắc để đề xuất các chính sách cho vay an toàn và hiệu quả hơn.

1.2: Mục tiêu nghiên cứu

Mục tiêu tổng quát của đề tài là ứng dụng các thuật toán học máy phân loại để xây dựng mô hình dự báo xác suất nợ quá hạn (Probability of Default) của khách hàng cá nhân. Thông qua đó, đề tài cung cấp cơ sở định lượng khách quan giúp đánh giá rủi ro tín dụng một cách tự động, tối ưu hóa quyết định phê duyệt khoản vay và kiểm soát hiệu quả tỷ lệ nợ xấu.

Các mục tiêu cụ thể bao gồm:

- Xây dựng một mô hình học máy có khả năng dự báo xác suất vỡ nợ của khách hàng dựa trên lịch sử tín dụng, đặc điểm khoản vay và thông tin định danh hợp lệ.
- Loại bỏ các yếu tố gây rò rỉ dữ liệu (data leakage) và các biến vi phạm quy định pháp lý về công bằng tín dụng (ECOA).

- So sánh hiệu suất giữa nhiều thuật toán (Logistic Regression, Random Forest, XGBoost) để lựa chọn mô hình tối ưu.
- Xác định ngưỡng quyết định (cut-off threshold) phù hợp dựa trên ma trận chi phí kinh doanh thay vì chỉ dựa vào chỉ số kỹ thuật.
- Ứng dụng SHAP để giải thích các yếu tố tác động đến quyết định của mô hình, phục vụ yêu cầu minh bạch hoá trong lĩnh vực tài chính – ngân hàng.

1.3: Đối tượng và phạm vi nghiên cứu

1.3.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu chính của đề tài là rủi ro tín dụng và xác suất vỡ nợ của khách hàng cá nhân (Retail Customers) thông qua việc phân tích các đặc trưng về năng lực tài chính, hồ sơ khoản vay và hành vi giao dịch tại Nova Bank.

1.3.2. Phạm vi nghiên cứu

- **Phạm vi về dữ liệu (Data Scope):** Nghiên cứu sử dụng bộ dữ liệu lịch sử tín dụng bao gồm 32.581 quan sát. Để đảm bảo tính khách quan của mô hình, ngăn chặn hiện tượng rò rỉ dữ liệu (Data Leakage) và tuân thủ nghiêm ngặt các quy định về chống phân biệt đối xử trong cho vay (Đạo luật ECOA), đề tài đã chủ động loại bỏ các biến nhãn nội bộ (như *Xếp hạng tín dụng - loan_grade*), các biến nhân khẩu học nhạy cảm (như giới tính, tình trạng hôn nhân) và các biến gây đa cộng tuyến. Các đặc trưng (Features) được giữ lại để đưa vào mô hình tập trung vào 3 nhóm chính:
    - *Nhóm năng lực tài chính & Cá nhân:* Độ tuổi, mức thu nhập hàng năm, thời gian làm việc (thâm niên công tác), tình trạng sở hữu nhà ở.
    - *Nhóm đặc tính khoản vay:* Quy mô khoản vay, mức lãi suất áp dụng, mục đích sử dụng vốn.
    - *Nhóm lịch sử tín dụng:* Số tài khoản tín dụng đang mở, tỷ lệ sử dụng hạn mức thẻ, số lần nợ quá hạn trong quá khứ.
- **Biến mục tiêu (Target Variable):** Phạm vi bài toán tập trung giải quyết mô hình phân loại nhị phân (Binary Classification) với biến mục tiêu là loan_status (Trạng thái khoản vay), được định nghĩa như sau:
    - Lớp 0 (Non-default): Khách hàng an toàn, thực hiện nghĩa vụ thanh toán đầy đủ và đúng hạn.
    - Lớp 1 (Default): Khách hàng rủi ro, có dấu hiệu mất khả năng thanh toán hoặc đã thực tế vỡ nợ.

- **Phương pháp (Methodological Scope):** Nghiên cứu giới hạn trong việc so sánh 3 thuật toán học máy có giám sát (Supervised Learning) phổ biến bao gồm: Hồi quy Logistic (Logistic Regression), Random Forest và XGBoost. Quá trình tối ưu hóa quyết định không chỉ dựa trên các chỉ số hiệu suất kỹ thuật (F1-Score, AUC) mà còn được mở rộng để đánh giá thông qua Ma trận chi phí kinh doanh (Cost Matrix) và công cụ diễn giải mô hình Explainable AI (SHAP).

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1: Rủi ro tín dụng

Rủi ro tín dụng (Credit Risk) là khả năng xảy ra tổn thất tài chính khi người vay không thực hiện đúng các điều khoản của hợp đồng tín dụng. Điều này có thể bao gồm việc chậm trả nợ, trả nợ không đầy đủ hoặc không trả nợ khi đến hạn các khoản gốc và lãi vay.

Các nguyên nhân chính:

- Phía khách hàng: Suy giảm năng lực tài chính, Rủi ro đạo đức
- Phía ngân hàng (Tổ chức cấp Tín dụng): Bất cân xứng thông tin, thẩm định chủ quan, chính sách tín dụng lỏng lẻo, buông lỏng quản lí sau giải ngân,..
- Môi trường khách quan: Biến động kinh tế Vĩ mô, thiên tai, dịch bệnh,…

2.2: Bài toán phân loại

Phân loại trong học máy là một quá trình mô hình dự đoán trong đó các mô hình học máy sử dụng các thuật toán phân loại để dự đoán nhãn chính xác cho dữ liệu đầu vào.

Khi các mô hình AI học cách phân tích và phân loại dữ liệu trong bộ dữ liệu huấn luyện, chúng trở nên thành thạo hơn trong việc nhận diện các loại dữ liệu khác nhau, phát hiện xu hướng và đưa ra dự đoán chính xác hơn.

Kết thúc quá trình huấn luyện mô hình, hiệu suất của mô hình được đánh giá bằng dữ liệu kiểm tra. Sau khi mô hình hoạt động ổn định, nó được đưa vào dữ liệu thực tế chưa từng thấy. Các mạng neural được huấn luyện áp dụng những gì chúng đã học trong quá trình đào tạo để đưa ra dự đoán thành công với dữ liệu mới.

Trong đề tài này:

- Input: Thông tin khách hàng.
- Output: loan_status.

2.3: Tiêu chí đánh giá mô hình

Do đặc thù của dữ liệu rủi ro tín dụng thường bị mất cân bằng (tỷ lệ nợ xấu luôn thấp hơn so với nợ tốt), dẫn đến việc chỉ sử dụng độ chính xác tổng thể (Accuracy) sẽ không phản ánh đúng thực tế. Vì vậy, đề án đã sử dụng các nhóm tiêu chí đánh giá khác như:

- **Nhóm tiêu chí đo lường kỹ thuật phân loại** Dựa trên Ma trận nhầm lẫn (Confusion Matrix), các chỉ số sau được sử dụng để đánh giá hiệu năng:
    - **Độ nhạy (Recall/Sensitivity):** Đo lường tỷ lệ nợ xấu (Default) mà mô hình nhận diện đúng trên tổng số nợ xấu thực tế. Trong rủi ro tín dụng, việc bỏ lọt một khách hàng nợ xấu (False Negative) gây hậu quả nghiêm trọng hơn rất nhiều so với việc từ chối nhầm một khách hàng tốt. Do đó, Recall là chỉ số được ưu tiên cao.
    - **Độ chuẩn xác (Precision):** Đo lường tỷ lệ khách hàng thực sự vỡ nợ trên tổng số khách hàng mà mô hình dự báo là vỡ nợ.
    - **F1-Score:** Là trung bình điều hòa của Precision và Recall, giúp đánh giá sự cân bằng của mô hình, đặc biệt hữu ích khi xử lý tập dữ liệu mất cân bằng.
- **Khả năng phân tách của mô hình (ROC-AUC)**
    - **Đường cong ROC (Receiver Operating Characteristic):** Biểu diễn sự đánh đổi giữa Tỷ lệ dự báo đúng nợ xấu (True Positive Rate) và Tỷ lệ dự báo sai nợ xấu (False Positive Rate) ở nhiều ngưỡng cắt (thresholds) khác nhau.
    - **Chỉ số AUC (Area Under the Curve):** Diện tích dưới đường cong ROC. AUC càng tiến gần về 1, mô hình càng có khả năng phân tách tốt giữa nhóm khách hàng trả nợ tốt và nhóm có rủi ro vỡ nợ.

2.4: Các mô hình nghiên cứu

2.4.1: Logistic Regression

Hồi quy logistic là một thuật toán được sử dụng để phân loại các quan sát theo các danh mục rời rạc. Thay vì có đầu ra là các giá trị liên tục như thuật toán hồi quy tuyến tính, hồi quy logistic đưa đầu ra qua hàm logistic sigmoid để trả về một giá trị biểu thị xác suất mà quan sát đầu vào thể hiện tính chất của hai hay nhiều hơn các danh mục rời rạc.

Lí do lựa chọn: Là mô hình cơ sở (baseline) mạnh mẽ. Đóng vai trò như mốc so sánh, tính minh bạch cao và dễ diễn giải tác động của từng biến bằng hệ số hồi quy (Coefficients).

2.4.2: Random Forest

Random Forest (Rừng ngẫu nhiên) là phương pháp học máy thuộc nhóm **ensemble learning** (học tập tổ hợp), kết hợp nhiều cây quyết định (decision trees) để đưa ra dự đoán cuối cùng. Hoạt động theo nguyên tắc *bagging*: mỗi cây được huấn luyện trên một tập con dữ liệu lấy mẫu bootstrap (có hoàn lại) và sử dụng tập đặc trưng ngẫu nhiên tại mỗi nút phân chia.

Lý do lựa chọn: Xử lý tốt các dữ liệu phi tuyến tính, giảm thiểu nguy cơ học vẹt (overfitting) và ổn định với các giá trị ngoại lai (outliers).

2.4.3: XGBoost

XGBoost, hay Extreme Gradient Boosting, là một thư viện phần mềm phân tán, được tối ưu hóa cao, được thiết kế để triển khai các thuật toán machine learning theo khuôn khổ Gradient Boosting. Nổi bật với tốc độ cực nhanh, chính xác cao và khả năng xử lí dữ liệu lớn.

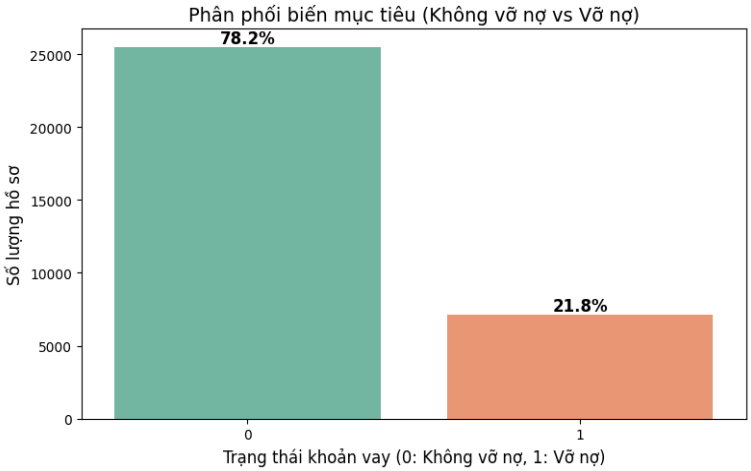
Lý do lựa chọn: Tốc độ hội tụ nhanh, mạnh mẽ trên dữ liệu dạng bảng (tabular data), hỗ trợ sẵn việc xử lý mất cân bằng lớp (thông qua scale_pos_weight) và cho hiệu năng dự báo AUC cao.

CHƯƠNG 3: DỮ LIỆU VÀ TIỀN XỬ LÍ DỮ LIỆU

3.1: Mô tả dữ liệu

Bộ dữ liệu tín dụng cá nhân của Nova Bank (Credit Risk Dataset) có kích thước ban đầu là 32.581 quan sát và 29 biến, bao gồm các nhóm thông tin chính: đặc điểm nhân khẩu học (tuổi, thu nhập, số năm kinh nghiệm làm việc, hình thức sở hữu nhà ở), đặc điểm khoản vay (số tiền vay, lãi suất, kỳ hạn vay, mục đích vay) và lịch sử tín dụng (số lần vi phạm nợ trong quá khứ, tỷ lệ sử dụng hạn mức tín dụng, số tài khoản đang mở).

Ở đây biến mục tiêu là loan_status. Một đặc trưng quan trọng của dữ liệu rủi ro tín dụng là sự mất cân đối giữa nợ tốt và nợ xấu. Đối với bộ dữ liệu được sử dụng trong đề án, con số chênh lệch xấp xỉ tỉ lệ 4/1 (khách tốt/khách xấu). Hậu quả là mô hình có thể đạt độ chính xác lên tới 80% chỉ bằng cách dự đoán tất cả khách hàng đều là người tốt, nhưng lại hoàn toàn thất bại trong việc nhận diện các khách hàng thực sự vỡ nợ (Lớp 1) – vốn là mục tiêu cốt lõi của bài toán.



Hình 3.1. Phân phối biến mục tiêu loan_status (Không vỡ nợ vs Vỡ nợ)

Định hướng xử lý trong mô hình: Để giải quyết bài toán này mà không làm biến dạng dữ liệu gốc hay vô tình gây rò rỉ thông tin (Data Leakage) thông qua các kỹ thuật sinh dữ liệu nhân tạo, đề án lựa chọn phương pháp **Học nhạy cảm với chi phí (Cost-sensitive Learning)**. Cụ thể, khi thiết lập các thuật toán như Random Forest hay XGBoost, mô hình sẽ được cung cấp một trọng số phạt lớn hơn (thông qua tham số class_weight="balanced" hoặc scale_pos_weight) mỗi khi phân loại sai một khách hàng thuộc Lớp 1, buộc thuật toán phải tập trung học cách nhận diện nhóm rủi ro thiểu số này.

Column Name	Mô tả
client_ID	Định danh duy nhất cho từng khách hàng
person_age	Tuổi của người nộp đơn (năm)
person_income	Thu nhập hàng năm của người nộp đơn (USD)
person_home_ownership	Tình trạng sở hữu nhà (THUÊ/SỞ HỮU/THẾ CHẤP)
person_emp_length	Thời gian làm việc (năm)
loan_intent	Mục đích của khoản vay (CÁ NHÂN, Y TẾ, GIÁO DỤC, v.v.)
loan_grade	Mức tín dụng được gán cho khoản vay (A–G)
loan_amnt	Số tiền vay yêu cầu (USD)
loan_int_rate	Lãi suất khoản vay (%)
loan_status	Tình trạng trả nợ khoản vay (0 = không vỡ nợ, 1 = nợ)
loan_percent_income	Tỷ lệ phần trăm thu nhập phân bổ cho việc trả nợ
cb_person_default_on_file	Người nộp đơn có từng vỡ nợ trước đây hay không (Y/N)
cb_person_cred_hist_length	Thời gian sử dụng tín dụng (năm)
gender	Giới tính của người nộp đơn (Nam/Nữ)
marital_status	Tình trạng hôn nhân (Độc thân/Kết hôn/Ly hôn/Góa chồng)
education_level	Trình độ học vấn (Trung học phổ thông/Cử nhân/Thạc sĩ/Tiến sĩ)
country	Quốc gia cư trú
state	Bang/Tỉnh cư trú
city	Thành phố cư trú
city_latitude	Tọa độ vĩ độ của thành phố
city_longitude	Tọa độ kinh độ của thành phố
employment_type	Loại hình việc làm (Toàn thời gian/Bán thời gian/Tự kinh doanh/Thất nghiệp)
loan_term_months	Thời hạn vay tính theo tháng (12, 24, 36, 60)
loan_to_income_ratio	Số tiền vay chia cho thu nhập của người nộp đơn
other_debt	Khoản nợ giả lập bổ sung do người nộp đơn nắm giữ (USD)
debt_to_income_ratio	Tổng nghĩa vụ nợ chia cho thu nhập của người nộp đơn
open_accounts	Số lượng tài khoản tín dụng đang mở
credit_utilization_ratio	Tỷ lệ sử dụng tín dụng (0–1)
past_delinquencies	Số lần quá hạn/thanh toán chậm

Bảng 1. Mô tả các biến trong bộ dữ liệu tín dụng cá nhân Nova Bank

3.2: Tiền xử lý

3.2.1: Kiểm tra giá trị thiếu

Qua kiểm tra giá trị missing, cho thấy chất lượng dữ liệu tổng thể ban đầu rất tốt, chỉ có 2 biến bị thiếu dữ liệu là loan_int_rate (3116 quan sát, 9.56%) và person_emp_length (895 quan sát, 2.75%). Tổng tỷ lệ giá trị khuyết thiếu chỉ quanh mức 10%.

Đây là 2 biến định lượng mang tín hiệu rủi ro cốt lõi. Việc loại bỏ 2 cột này là không cần thiết và làm mất thông tin dự báo. Còn nếu xoá bỏ các dòng missing có thể sẽ dẫn tới sự mất cân bằng nghiêm trọng.

Do đó trong đề án này, phương án được lựa chọn là điền khuyết bằng giá trị trung vị. So với trung bình (mean), trung vị có khả năng kháng nhiễu tốt hơn và tránh bị bóp méo bởi các giá trị ngoại lai (outliers).

3.2.2: Xử lí outliers

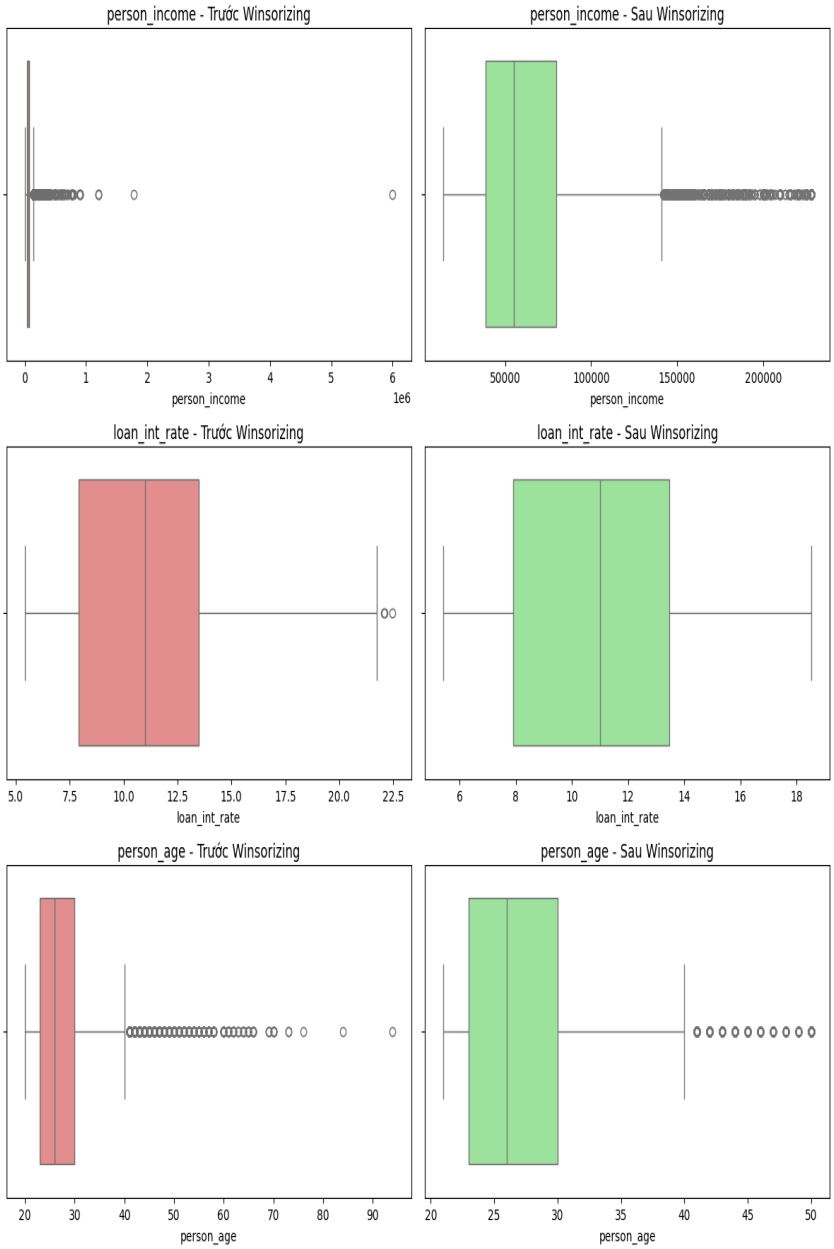
Thông qua thống kê mô tả, dữ liệu ghi nhận một số quan sát mang giá trị không hợp lý về mặt sinh học và thực tiễn lao động, điển hình như: độ tuổi khách hàng (person_age) vượt quá 100 tuổi, hoặc thâm niên công tác (person_emp_length) lớn hơn 60 năm dù độ tuổi ghi nhận chỉ 23 năm. Đây được xác định là các lỗi do con người hoặc hệ thống (Data Entry Errors) trong quá trình thu thập thông tin.

Chiến lược xử lý: Các quan sát vi phạm ranh giới logic này được gán giá trị khuyết (NaN) và xử lý bằng kỹ thuật điền khuyết trung vị tương tự mục 3.2.1, thay vì loại bỏ hoàn toàn để tránh làm mất mẫu quan sát

Đối với các biến tài chính định lượng (như person_income, loan_amnt), dữ liệu thường có phân phối lệch phải (right-skewed) với một số khách hàng có mức thu nhập hoặc khoản vay cao đột biến. Nếu áp dụng phương pháp truyền thống là xóa bỏ (drop) các quan sát cực đoan này, ngân hàng sẽ làm giảm đáng kể kích thước tập mẫu và vô tình đánh mất thông tin của phân khúc khách hàng cao cấp (VIP).

Do đó, đề án sử dụng kỹ thuật **Winsorizing** thông qua việc xây dựng một lớp tùy chỉnh (Custom Transformer) tích hợp thẳng vào quy trình tự động hóa (Pipeline) của mô hình.

- **Cơ chế hoạt động:** Thay vì loại bỏ, thuật toán sẽ thực hiện "cắt ngọn" (clipping) dữ liệu tại hai đầu phân phối. Cụ thể, các giá trị nhỏ hơn phân vị 1% (Lower Quantile = 0.01) sẽ được gán bằng chính giá trị tại phân vị 1%; tương tự, các giá trị lớn hơn phân vị 99% (Upper Quantile = 0.99) sẽ được gán bằng giá trị tại phân vị 99%.
- **Hiệu quả:** Kỹ thuật này giúp bảo toàn tuyệt đối số lượng quan sát của tập dữ liệu, đồng thời "làm mềm" các điểm dị biệt. Điều này giúp các biến đầu vào đạt được sự ổn định phân phối (robustness), từ đó hạn chế tối đa độ lệch (bias) trong quá trình máy học cập nhật trọng số.



Hình 3.2. Boxplot so sánh trước/sau Winsorizing của person_income, loan_int_rate, person_age

3.2.3: Mã hoá biến phân loại

Bộ dữ liệu tín dụng chứa nhiều biến định tính mô tả các thuộc tính phi số của khách hàng (như mục đích vay loan_intent, loại hình việc làm employment_type, hay hình thức sở hữu nhà person_home_ownership).

Để giải quyết vấn đề này, đề án áp dụng kỹ thuật **Mã hóa One-Hot (One-Hot Encoding)**. Phương pháp này thực hiện việc chuyển đổi mỗi hạng mục (category) của một biến định tính thành một biến giả (dummy variable) độc lập mang giá trị nhị phân (0 hoặc 1).

Việc sử dụng One-Hot Encoding giúp mô hình nhận diện chính xác sự khác biệt giữa các nhóm phân loại mà không vô tình tạo ra một thứ tự phân cấp giả tạo

3.2.4: Chuẩn hoá dữ liệu

Các biến độc lập định lượng trong bộ dữ liệu có sự chênh lệch rất lớn về mặt thang đo (scale). Cụ thể, quy mô khoản vay (loan_amnt) hay thu nhập (person_income) thường nằm ở mức hàng chục đến hàng trăm nghìn, trong khi các biến như lãi suất (loan_int_rate) hoặc số lượng tài khoản tín dụng (open_accounts) lại có giá trị rất nhỏ.

Nhằm đưa các biến này về cùng một hệ quy chiếu, đề án tích hợp phương pháp chuẩn hóa **StandardScaler** vào luồng xử lý dữ liệu. Kỹ thuật này sẽ biến đổi phân phối của từng biến số sao cho giá trị trung bình (Mean) bằng 0 và độ lệch chuẩn (Standard Deviation) bằng 1.

3.3: Kiểm định đa cộng tuyến và phân chia dữ liệu

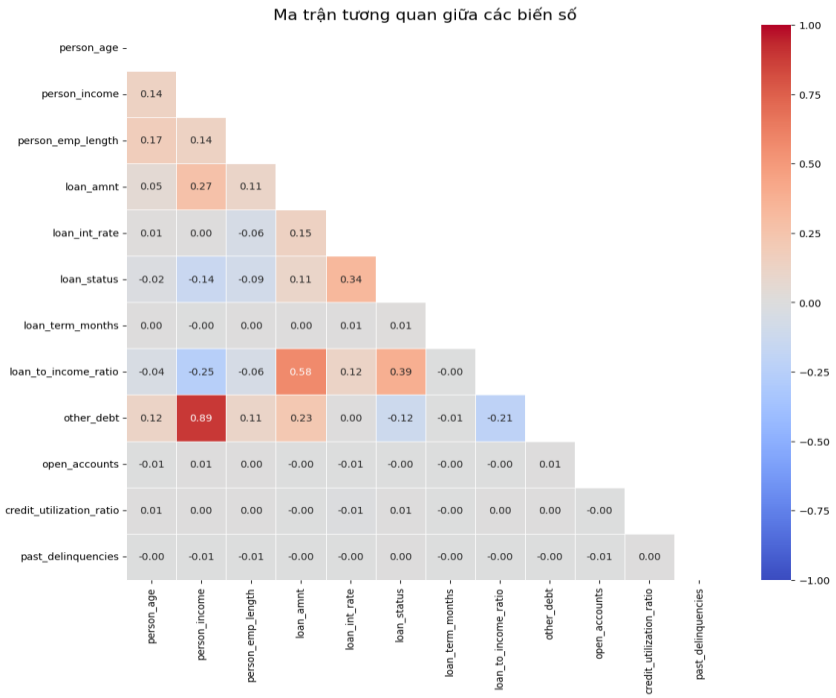
Trước khi huấn luyện mô hình, đề án thực hiện kiểm định hệ số phóng đại phương sai (VIF - Variance Inflation Factor) trên các biến số nhằm xác nhận rằng hiện tượng đa cộng tuyến đã được xử lý ở mức chấp nhận được (ngưỡng VIF < 15). Kết quả kiểm định được trình bày trong bảng dưới đây:

Biến số	Hệ số VIF
person_age	14.17
person_income	11.36
loan_int_rate	10.90
other_debt	8.39
loan_to_income_ratio	7.02
loan_amnt	6.96
loan_term_months	6.02
credit_utilization_ratio	4.36
open_accounts	4.13
person_emp_length	2.57
past_delinquencies	1.49

Bảng 2: Hệ số phóng đại phương sai (VIF) của các biến số trước khi huấn luyện mô hình

Kết quả cho thấy toàn bộ hệ số VIF đều nhỏ hơn ngưỡng 15, cho thấy hiện tượng đa cộng tuyến giữa các biến số đã được kiểm soát tốt sau khi loại bỏ các biến trùng lặp thông tin (loan_percent_income, cb_person_cred_hist_length, debt_to_income_ratio) ở bước lựa chọn đặc trưng.

Biểu đồ nhiệt (heatmap) dưới đây thể hiện hệ số tương quan Pearson giữa các biến số trong bộ dữ liệu, bổ sung trực quan cho kết quả kiểm định VIF ở trên, giúp dễ dàng nhận diện các cặp biến có mối quan hệ tuyến tính mạnh.



Hình 3.3. Ma trận tương quan giữa các biến số

Sau bước xử lý, dữ liệu được chia thành ba tập theo phương pháp phân tầng (stratified sampling) nhằm giữ nguyên tỷ lệ khách hàng vỡ nợ giữa các tập:

Tập dữ liệu	Số quan sát	Vai trò
Train (Huấn luyện)	22.806	Huấn luyện mô hình (70%)
Validation (Định cỡ)	4.887	Hiệu chỉnh ngưỡng quyết định (15%)
Test (Kiểm thử)	4.888	Đánh giá khách quan cuối cùng (15%)

Bảng 3: Kích thước các tập dữ liệu Train / Validation / Test

CHƯƠNG 4: PHÂN TÍCH KẾT QUẢ MÔ HÌNH HỌC MÁY

4.1: So sánh hiệu suất các mô hình cơ sở

Ba thuật toán học máy được huấn luyện và so sánh bằng phương pháp kiểm định chéo 5-Fold trên tập Train, sử dụng chỉ số ROC-AUC làm tiêu chí đánh giá:

Mô hình	AUC trung bình	Độ lệch chuẩn
Logistic Regression	0.8516	± 0.0049
Random Forest	0.9071	± 0.0028
XGBoost	0.9263	± 0.0055

Bảng 4: Kết quả so sánh hiệu suất các mô hình cơ sở bằng 5-Fold Cross Validation

Kết quả cho thấy XGBoost đạt hiệu suất phân tách cao nhất (AUC = 0.9263), vượt trội so với Random Forest (0.9071) và Logistic Regression (0.8516). Do đó, XGBoost được lựa chọn làm mô hình ứng viên chính để tiếp tục tối ưu hoá siêu tham số.

4.2: Tối ưu hoá siêu tham số cho mô hình XGBoost

Việc tinh chỉnh siêu tham số được thực hiện bằng RandomizedSearchCV (20 tổ hợp, 3-Fold Cross Validation) kết hợp cơ chế Early Stopping (50 vòng) trên tập Validation nhằm hạn chế hiện tượng quá khớp (overfitting). Bộ siêu tham số tối ưu tìm được như sau:

Siêu tham số	Giá trị tối ưu
n_estimators	1000
learning_rate	0.05
max_depth	4
min_child_weight	5
subsample	0.8
colsample_bytree	0.6
reg_alpha	0
reg_lambda	5.0
gamma	0

Bảng 5: Bộ siêu tham số tối ưu của mô hình XGBoost sau RandomizedSearchCV

4.3: Xác định ngưỡng quyết định theo chi phí kinh doanh

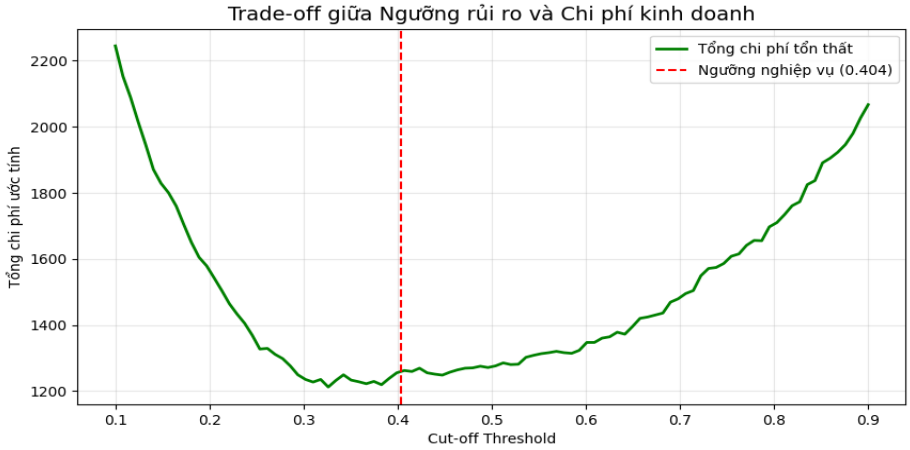
Trên tập Validation, hai chiến lược xác định ngưỡng quyết định được so sánh: (1) tối đa hoá F1-Score kỹ thuật, và (2) tối thiểu hoá tổng chi phí kinh doanh, với giả định tổn thất do duyệt nhầm khách hàng vỡ nợ (False Negative) gấp 5 lần tổn thất do từ chối nhầm khách hàng tốt (False Positive).

Chiến lược hiệu chỉnh ngưỡng	Ngưỡng tối ưu
Tối đa hoá F1-Score	0.670
Tối thiểu hoá chi phí kinh doanh (FN : FP = 5 : 1)	0.404

Bảng 6: Ngưỡng quyết định theo hai chiến lược hiệu chỉnh

Ngưỡng quyết định cuối cùng được lựa chọn theo tiêu chí chi phí kinh doanh (0.404) thay vì ngưỡng tối ưu F1 kỹ thuật (0.670), nhằm ưu tiên giảm thiểu rủi ro duyệt nhầm các khoản vay có khả năng vỡ nợ cao, phù hợp với khẩu vị rủi ro thận trọng của ngân hàng.

Biểu đồ dưới đây thể hiện tổng chi phí ước tính (theo ma trận chi phí FN : FP = 5 : 1) tại từng mức ngưỡng quyết định khác nhau, minh hoạ trực quan lý do ngưỡng 0.404 được lựa chọn làm ngưỡng vận hành chính thức thay vì ngưỡng tối ưu F1-Score kỹ thuật (0.670).



Hình 4.1. Trade-off giữa ngưỡng quyết định (threshold) và tổng chi phí kinh doanh ước tính

4.4: Đánh giá kết quả trên tập kiểm thử độc lập

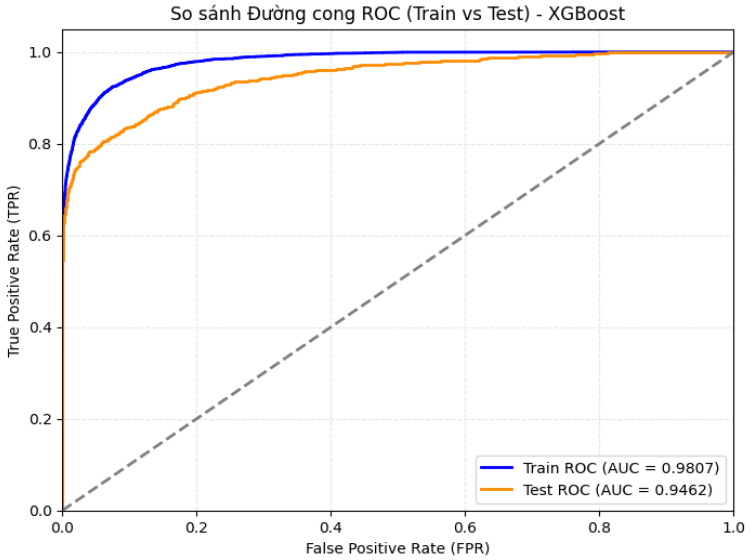
Mô hình sau tối ưu được đánh giá một lần duy nhất trên tập Test (chưa từng được sử dụng trong quá trình huấn luyện hay hiệu chỉnh) nhằm phản ánh trung thực năng lực dự báo thực tế:

Chỉ số	Giá trị
AUC – Tập Train	0.9807
AUC – Tập Test	0.9462

Bảng 7: So sánh AUC giữa tập Train và tập Test

Chênh lệch giữa AUC tập Train (0.9807) và AUC tập Test (0.9462) ở mức chấp nhận được, cho thấy mô hình không bị quá khớp nghiêm trọng và có khả năng khái quát hoá tốt trên dữ liệu chưa từng gặp.

Đường cong ROC dưới đây minh hoạ trực quan cho các chỉ số AUC nêu trên. Khoảng cách giữa hai đường cong Train và Test không quá lớn, một lần nữa củng cố nhận định mô hình có khả năng khái quát hoá tốt trên dữ liệu mới.



Hình 4.2. Đường cong ROC của mô hình XGBoost trên tập Train và tập Test

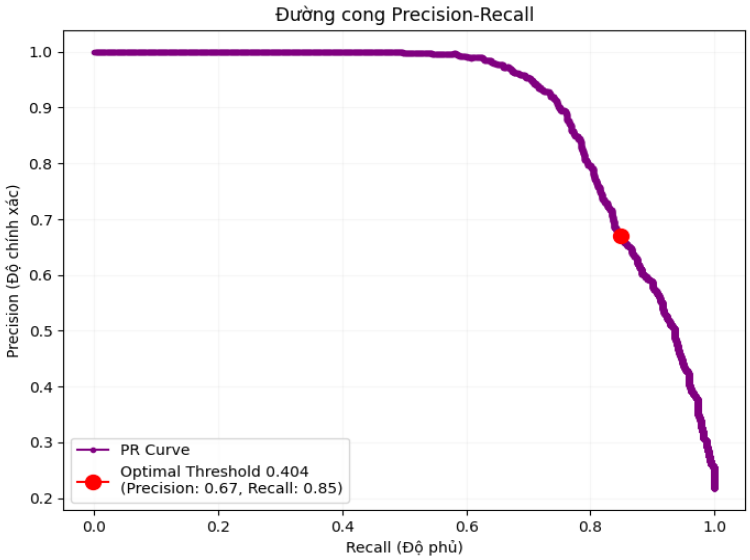
Áp dụng ngưỡng quyết định 0.404 (theo chi phí kinh doanh), báo cáo phân loại chi tiết trên tập Test như sau:

Nhãn	Precision	Recall	F1-score	Support
0 – Không vỡ nợ	0.95	0.88	0.92	3.821
1 – Vỡ nợ	0.67	0.85	0.75	1.067
Accuracy			0.88	4.888
Macro avg	0.81	0.87	0.83	4.888
Weighted avg	0.89	0.88	0.88	4.888

Bảng 8: Báo cáo phân loại chi tiết trên tập Test (ngưỡng quyết định = 0.404)

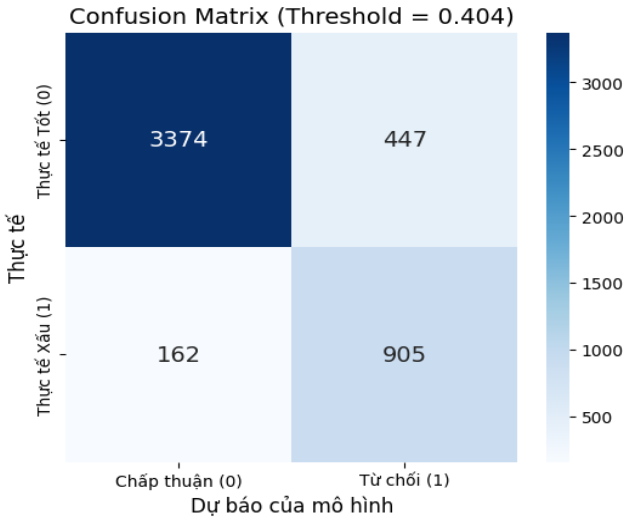
Kết quả cho thấy mô hình đạt độ chính xác tổng thể (accuracy) 88% trên tập Test. Đáng chú ý, với nhóm khách hàng có nguy cơ vỡ nợ (nhãn 1), mô hình đạt Recall 0.85 — nghĩa là phát hiện được 85% các trường hợp vỡ nợ thực tế, phù hợp với mục tiêu ưu tiên giảm thiểu rủi ro duyệt nhầm khoản vay xấu đã đặt ra ở bước hiệu chỉnh ngưỡng.

Đường cong Precision–Recall trên tập Test, có đánh dấu vị trí ngưỡng quyết định 0.404 đã được lựa chọn theo tiêu chí chi phí kinh doanh, giúp hình dung trực quan sự đánh đổi (trade-off) giữa Precision và Recall tại điểm vận hành thực tế của mô hình.



Hình 4.3. Đường cong Precision–Recall với điểm ngưỡng tối ưu 0.404

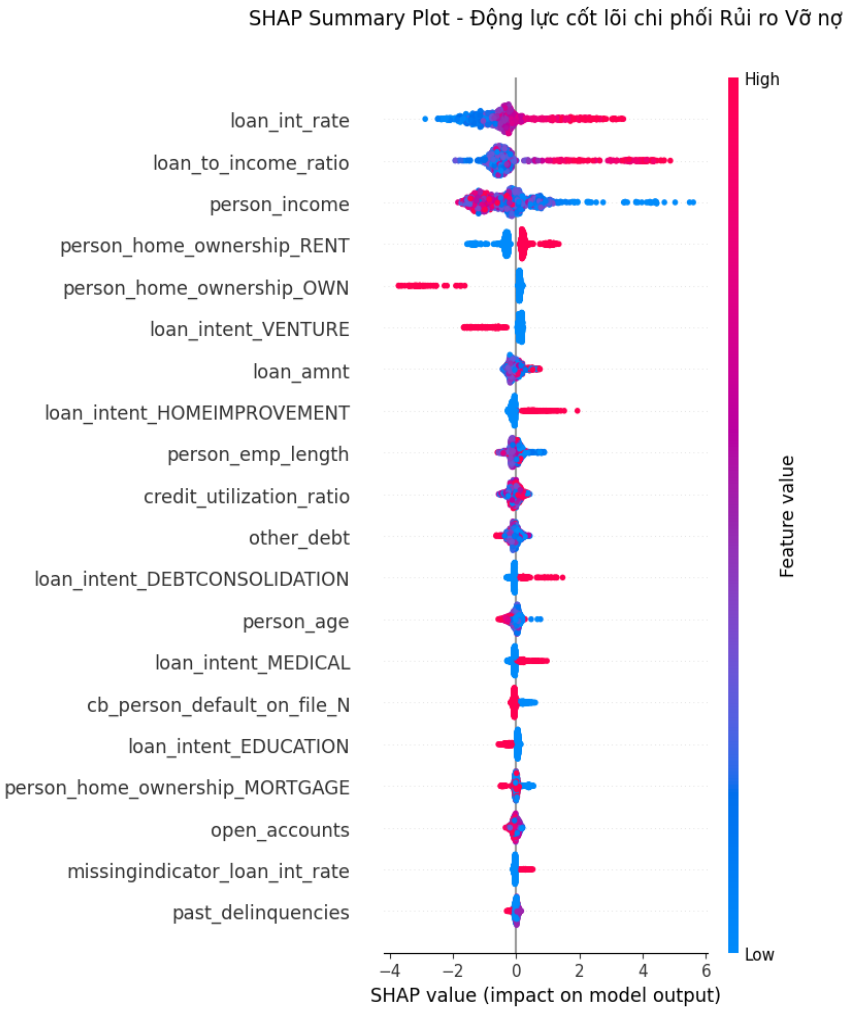
Ma trận nhầm lẫn dưới đây thể hiện trực quan số lượng hồ sơ được phân loại đúng/sai ở từng nhóm, tương ứng với báo cáo phân loại tại Bảng 8, khi áp dụng ngưỡng quyết định 0.404.



Hình 4.4. Ma trận nhầm lẫn trên Test tại ngưỡng quyết định 0.404

4.5: Giải thích mô hình bằng SHAP

Để đảm bảo tính minh bạch của mô hình "hộp đen" (black-box) XGBoost trước yêu cầu thanh tra và tuân thủ trong lĩnh vực ngân hàng, đề án sử dụng phương pháp SHAP (TreeExplainer) để lượng hoá mức độ và chiều tác động của từng biến đến xác suất vỡ nợ dự báo, dựa trên mẫu 1.000 quan sát ngẫu nhiên từ tập Test.



Hình 4.5. Biểu đồ SHAP Summary Plot – Các yếu tố cốt lõi chi phối rủi ro vỡ nợ

Biểu đồ SHAP cho phép xác định các biến số có mức độ ảnh hưởng lớn nhất đến quyết định của mô hình, đồng thời cho biết chiều hướng tác động (làm tăng hay giảm xác suất vỡ nợ) của từng giá trị biến. Đây là cơ sở quan trọng để bộ phận Quản trị Rủi ro của ngân hàng giải trình lý do chấp thuận hoặc từ chối một hồ sơ vay cụ thể, đồng thời phục vụ việc giám sát định kỳ các chỉ số công bằng (fairness) đối với các biến có khả năng đóng vai trò đại diện (proxy) cho các nhóm yếu tố kinh tế – xã hội.

CHƯƠNG 5: HẠN CHẾ CỦA ĐỀ TÀI VÀ HƯỚNG PHÁT TRIỂN

Mặc dù đề án đã xây dựng thành công quy trình đánh giá rủi ro tín dụng tự động với hiệu suất dự báo cao và tối ưu được bài toán chi phí kinh doanh, nghiên cứu vẫn còn tồn tại một số giới hạn nhất định và mở ra các hướng phát triển trong tương lai.

5.1: Hạn chế

- Dữ liệu sử dụng trong đề án mang tính chất minh hoạ tổng hợp.
- Sự mất cân bằng trong dữ liệu có thể khiến cho mô hình chỉ cần dự báo nợ tốt 100% thì Accuracy cũng gần đạt mức 80%
- Mô hình cần được cập nhật, tái huấn luyện theo chu kỳ phù hợp để duy trì độ chính xác dự báo theo thời gian, khi hành vi và đặc điểm khách hàng thay đổi.
- Đề án mới dừng lại ở bài toán phân loại nhị phân (vỡ nợ/không vỡ nợ), chưa mở rộng sang dự báo giá trị tổn thất khi vỡ nợ (Loss Given Default) hay thời điểm vỡ nợ, đây là hướng phát triển tiềm năng cho các nghiên cứu tiếp theo.
- Chưa giám sát tính công bằng (fairness) lâu dài: Một số biến như khu vực cư trú có khả năng đóng vai trò "đại diện" (proxy) cho các yếu tố kinh tế – xã hội.

5.2: Hướng phát triển

- **Tích hợp Dữ liệu thay thế (Alternative Data):** Mở rộng nguồn dữ liệu đầu vào bằng cách thu thập các dữ liệu phi truyền thống (ví dụ: hóa đơn thanh toán điện nước, cước viễn thông, hoặc hành vi trên ứng dụng ngân hàng số). Việc này sẽ giúp ngân hàng chấm điểm tín dụng được cho cả phân khúc khách hàng chưa có lịch sử giao dịch (Thin-file/Unbanked Customers).
- **Kiểm tra sức chịu đựng (Stress Testing):** Đưa thêm các kịch bản biến động kinh tế vĩ mô vào mô hình để đo lường sự thay đổi của xác suất vỡ nợ (PD). Điều này giúp ngân hàng dự phóng được rủi ro danh mục trong các điều kiện thị trường khắc nghiệt.
- **Chuyển đổi sang Thẻ điểm tín dụng (Scorecard Transformation):** Ứng dụng kỹ thuật phân nhóm (Binning) kết hợp với Weight of Evidence (WoE) để ánh xạ kết quả dự báo của các mô hình học máy phức tạp về dạng Thẻ điểm tín dụng (Credit Scorecard) truyền thống. Điều này giúp nhân viên tín dụng (End-users) dễ dàng vận hành và giải thích kết quả cho khách hàng một cách trực quan nhất.
- **Cân bằng dữ liệu với SMOTE**, thử nghiệm kỹ thuật sinh mẫu tổng hợp SMOTE trên tập Train nhằm cân bằng tỷ lệ hai lớp, đồng thời vẫn giữ nguyên phân phối gốc trên tập Validation/Test để đảm bảo tính khách quan khi đánh giá.

KẾT LUẬN

Đề án đã xây dựng thành công một mô hình học máy dự báo xác suất vỡ nợ cho khách hàng tín dụng cá nhân của Nova Bank, dựa trên thuật toán XGBoost sau khi so sánh với Logistic Regression và Random Forest. Mô hình đạt AUC 0.9462 trên tập kiểm thử độc lập, với mức chênh lệch so với tập huấn luyện (0.9807) ở ngưỡng chấp nhận được, cho thấy khả năng khái quát hoá tốt. Việc lựa chọn ngưỡng quyết định dựa trên ma trận chi phí kinh doanh (thay vì chỉ dựa vào F1-Score kỹ thuật) giúp mô hình ưu tiên giảm thiểu tổn thất do duyệt nhầm các khoản vay có nguy cơ vỡ nợ cao, phù hợp với thực tiễn quản trị rủi ro tín dụng. Bên cạnh đó, việc loại bỏ các biến gây rò rỉ dữ liệu và các biến bị hạn chế theo quy định pháp luật, cùng với việc ứng dụng SHAP để giải thích mô hình, giúp đảm bảo mô hình vừa có hiệu suất dự báo cao vừa đáp ứng các yêu cầu về tuân thủ và minh bạch trong lĩnh vực tài chính – ngân hàng.

TÀI LIỆU THAM KHẢO

1. Phạm Đại Phước (2025), *"Rủi ro tín dụng là gì? Các loại rủi ro tín dụng? Ví dụ cụ thể?"*, Thư Viện Pháp Luật, truy cập tại: https://thuvienphapluat.vn/lao-dong-tien-luong/rui-ro-tin-dung-la-gi-cac-loai-rui-ro-tin-dung-vi-du-cu-the-nguoi-lao-dong-co-chuc-vu-trong-to-chuc-30729.html

2. ML Glossary VN (2017), *"Hồi quy Logistic (Logistic Regression)"*, truy cập tại: https://ml-glossary-vn.readthedocs.io/vi/latest/logistic_regression_vn.html

3. Belcic, I. (2024), *"What is Classification in Machine Learning?"*, IBM Think, truy cập tại: https://www.ibm.com/think/topics/classification-machine-learning

4. Breiman, L. (2001), *"Random Forests"*, *Machine Learning*, Vol. 45, No. 1, pp. 5–32.

5. Chen, T., & Guestrin, C. (2016), *"XGBoost: A Scalable Tree Boosting System"*, *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.

6. Cox, D. R. (1958), *"The Regression Analysis of Binary Sequences"*, *Journal of the Royal Statistical Society: Series B*, Vol. 20, No. 2, pp. 215–242.

7. Lundberg, S. M., & Lee, S.-I. (2017), *"A Unified Approach to Interpreting Model Predictions"*, *Advances in Neural Information Processing Systems (NeurIPS) 30*.

8. Fawcett, T. (2006), *"An Introduction to ROC Analysis"*, *Pattern Recognition Letters*, Vol. 27, No. 8, pp. 861–874.

9. Kutner, M. H., Nachtsheim, C. J., & Neter, J. (2004), *Applied Linear Regression Models*, 4th edition, McGraw-Hill/Irwin — chương về hệ số phóng đại phương sai (VIF) và đa cộng tuyến.

10. U.S. Congress (1974), *Equal Credit Opportunity Act (ECOA)*, 15 U.S.C. § 1691 et seq.